실무에 활용하는 ElasticSearch 검색엔진 구축 3기
2일차 : 색인 및 매핑

2018.02

오늘의 아젠다

색인 운용 기법

데이터 색인

매핑 설계

데이터 색인

Elasticsearch 데이터 처리

- 엘라스틱서치는 주로 REST API를 통하여 데이터를 처리
- HTTP METHOD는 GET, POST, PUT, DELETE, HEAD 등이 있음
- 엘라스틱서치의 REST API를 이용하기 위한 형태는 아래와 같음

curl –X{METHOD} http://host:port/{INDEX}/{TYPE}/{ID} –d '{DATA}'

HTTP METHOD, CRUD, SQL 비교

HTTP METHOD	CRUD	SQL
GET	READ	SELECT
PUT	UPDATE	UPDATE
POST	CREATE	INSERT
DELETE	DELETE	DELETE

RESTFul이란?

REST는 웹의 창시자(HTTP) 중의 한 사람인 Roy Fielding의 2000년 논문에 의해서 소개
현재의 아키텍쳐가 웹의 본래 설계의 우수성을 많이 사용하지 못하고 있다고 판단
웹의 장점을 최대한 활용할 수 있는 네트워크 기반의 아키텍쳐를 소개
그것이 바로 Representational state transfer (REST)

REST는 요소로는 크게 리소스,메서드,메세지

HTTP POST , http://myweb/users/
{ Method Resource (URI)
"users":{
"name":"terry"
} Message
}

메서드	의미	Idempotent
POST	Create	No
GET	Select	Yes
PUT	Update	Yes
DELETE	Delete	Yes

CRUD를 메서드로 표현

데이터 입력

- POST나 PUT 메서드를 이용해 입력
- 처음 입력 시 created는 true
- 도큐먼트 ID를 생략하고 입력 가능
- 임의 ID 입력은 POST 메서드로만 가능

```
$ curl -XPUT http://localhost:9200/books/book/1 -d '
{
  "title": "Elasticsearch Guide",
  "author": "Kim",
  "date": "2015-06-25",
  "pages": 250
}'
```

데이터 삭제

- DELETE 메서드를 이용해 삭제
- 검색을 이용해 선별적 삭제 가능
- 타입과 인덱스 단위로 삭제 가능
- 인덱스 단위로 삭제할 경우 타입, 도큐먼트가 모두 삭제됨
- 도큐먼트는 삭제 후에도 메타 데이터를 그대로 보존

```
$ curl -XDELETE http://localhost:9200/books/book/AU4eDMKk5_2R8Icukymj
```

데이터 갱신

- PUT 메서드를 이용해 갱신
- 갱신 시 created는 false
- _version 필드가 증가
- 기존 도큐먼트는 보관되지 않으며 삭제되고 새로 쓰임
- 이전 버전으로 변경 불가능

```
$ curl -XPOST http://localhost:9200/books/book/ -d '
{
  "title": "Elasticsearch Guide",
  "author": ["Kim", "Lee"],
  "date": "2015-06-25",
  "pages": 300
}'
```

벌크 입력 (Bulk Insert)

```
curl -XPOST localhost:9200/_bulk -d '

{ "index" : { "_index" : "books", "_type" : "book", "_id" : "1" } }
{ "title" : "Elasticsearch Guide", "author" : "Kim", "pages" : 250 }
{ "index" : { "_index" : "books", "_type" : "book", "_id" : "2" } }
{ "title" : "Elasticsearch Easy Guide", "author" : "Lee", "pages" : 300 }
{ "delete" : { "_index" : "books", "_type" : "book", "_id" : "1" } }
{ "update" : { "_index" : "books", "_type" : "book", "_id" : "2" } }
{ "doc" : {"date" : "2014-05-01"} }
{ "create" : { "_index" : "books", "_type" : "book", "_id" : "3" } }
{ "title" : "Elasticsearch Guide II", "author" : "Park", "pages" : 400 }

‘
```

실습해보기

JSON으로 직접 데이터를 입력,수정,삭제 해보기
cerebro 혹은 크롬 Postman 이용

실습파일 참조

Elasticsearch client

Low level Client

How Level Client

Transport Client

JEST : Apache HttpComponents 프로젝트를 이용해서 만든 경량 클라이언트

Spring Data Elasticsearch : 스프링 데이터 레파지토리를 추상화하여 영속화 저장소를 위한 데이터 엑세스 레이어 구성

실습해보기

github에서 소스체크 아웃
혹은 아래 링크에서 소스 다운로드

매핑 설계

매핑이란?

ElasticSearch 별도스키마 설정이 없이도 자동으로 자료구조를 이해하고 저장 (동적 매핑)
특정 인덱스의 명시적 구조를 정의
한 인덱스에 매핑을 여러개 만들수 있으나필드명은 중복 불가
매핑은 필드의 추가는 가능, 수정 삭제는 불가능
예외)
신규 속성은 객체 데이터타입 필드에 추가 가능
신규 다중필드는 기존 필드에 추가 가능
doc_values 는 비활성화 될 수 있지만, 다시 활성화 불가
ignore_above는 수정 가능

기존 매핑과 충돌의 경우 무시하는 옵션이 있었으나 Deprecated (~~ignore_conflicts~~)
매핑 삭제 옵션은 제공X (~~2.0부터 DELETE mapping API 없음~~)

매핑 입력 및 조회

인덱스 생성시 입력

```
curl -XPOST ...:9200/my_index -d '{
    "settings" : {
        # .. index settings
    },
    "mappings" : {
        "my_type" : {
            # mapping for my_type
        }
    }
}'
```

매핑 API를 이용한 입력

```
$ curl -XPUT 'http://localhost:9200/my_index/my_type/_mapping' -d '
{
    "my_type" : {
        # mapping for my_type
    }
}
'
```

조회

```
curl -XGET ‘localhost:9200/news/_mapping/article?pretty’
```

필드 데이터타입 (Mapping datatype)

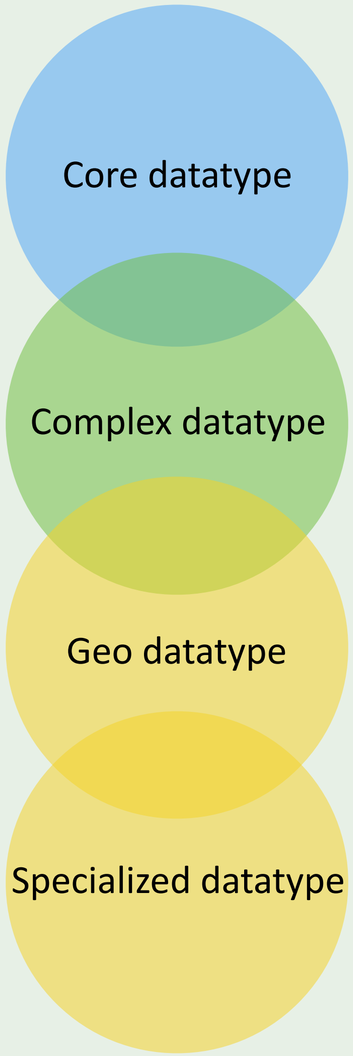

String : text, keyword
Numeric datatypes : long, integer, short, byte, double, float, half_float, scaled_float

Array datatype
Object datatype
Nested datatype

Geo-point datatype
Geo-Shape datatype

IP datatype
Completion datatype
Token count datatype
mapper-murmur3
Percolator type
join datatype

메타 필드

_all 필드 : 모든 필드를 하나로 합쳐서 색인함 (필드명 없는 검색에 대응)

_field_names 필드 : 필드 이름 자체를 검색하고자 할때

_id field : 키값 저장

_index field : 다중 인덱스 질의시 어떤 인덱스의 값인지 알기 위함

_meta field : 추가 메타 정보 입력

_routing field : 라우팅 정보 저장

_source field : 원본 정보 저장

_type field : 어떤 타입 정보인지 알기 위함 (Deprecated)

매핑 파라메터(Mapping parameters)

analyzer : 분석기 지정 (Default standard)
boost : 필드별 가중치
fielddata : 집계 정렬을 위해 필드데이터를 메모리에 올릴것인지 여부
fields : 집계나 정렬을 위해 같은 값을 다른 분석기로 분석할지 여부
index : 색인 할것인지 여부(default false)
index_options : 색인시 텀,빈도,포지션,오프셋 값을 저장할것인지 여부
- docs
- freqs
- positions (근접 연산자 및 phrase 검색시, 스트링 필드의 기본 값)
- offsets (하일라이팅)

norms : 스코어링에서 문서의 길이를 적용시킬것인지
store : 데이터를 저장 할것인지 여부 (_source 와 별도)
search_analyzer : 검색시 분석기를 별도로 지정할 것인지 여부
term_vector : 텀벡터를 저장할 것인지 여부
copy_to : 필드의 원본을 복사하여 다른 필드로 전송
similarity : 스코어 유사도 계산 방식을 정함 (classic/bm25/boo

Array datatype VS Object datatype VS Nested datatype

```
{
 "title": "Nest eggs",
 "body":  "Making your money work...",
 "tags":  [ "cash", "shares" ],
 "comments": [
   {
    "name":    "John Smith",
    "comment": "Great article",
    "age":     28,
    "stars":   4,
    "date":    "2014-09-01"
   },
   {
    "name":    "Alice White",
    "comment": "More like this please",
    "age":     31,
    "stars":   5,
    "date":    "2014-10-22"
   }
 ]
}
```

검색

```
GET /_search
{
 "query": {
   "bool": {
     "must": [
       { "match": { "name": "Alice" }},
       { "match": { "age":  28      }}
     ]
   }
 }
}
```

```
{
 "title":           [ eggs, nest ],
 "body":            [ making, money, work, your ],
 "tags":            [ cash, shares ],
 "comments.name":    [ alice, john, smith, white ],
 "comments.comment": [ article, great, like, more, please, this ],
 "comments.age":     [ 28, 31 ],
 "comments.stars":   [ 4, 5 ],
 "comments.date":    [ 2014-09-01, 2014-10-22 ]
}
```

cross-object 매칭 발생

Array datatype VS Object datatype VS Nested datatype

이러한 문제를 풀기 위해 nested objects가 디자인

단 내포된 오브젝트 만으로 검색 결과로 리턴될 수 없음

```
{ (1)
 "comments.name":    [ john, smith ],
 "comments.comment": [ article, great ],
 "comments.age":     [ 28 ],
 "comments.stars":   [ 4 ],
 "comments.date":    [ 2014-09-01 ]
}
{ (2)
 "comments.name":    [ alice, white ],
 "comments.comment": [ like, more, please, this ],
 "comments.age":     [ 31 ],
 "comments.stars":   [ 5 ],
 "comments.date":    [ 2014-10-22 ]
}
{ (3)
 "title":          [ eggs, nest ],
 "body":           [ making, money, work, your ],
 "tags":           [ cash, shares ]
}
```

```
PUT /my_index
{
 "mappings": {
  "blogpost": {
   "properties": {
    "comments": {
     "type": "nested",
     "properties": {
      "name":    { "type": "string"  },
      "comment": { "type": "string"  },
      "age":     { "type": "short"   },
      "stars":   { "type": "short"   },
      "date":    { "type": "date"    }
     }
    }
   }
  }
 }
}
```

nested query 사용

```
GET /my_index/blogpost/_search
{
 "query": {
  "bool": {
   "must": [
    { "match": { "title": "eggs" }}, (1)
    {
     "nested": {
      "path": "comments", (2)
      "query": {
       "bool": {
        "must": [
         { "match": { "comments.name": "john" }},(3)
         { "match": { "comments.age":  28     }}
        ]
       }}}}
   ]
}}}
```

매핑 문법

```
{
  "mappings": {
    "_doc": {
      "properties": {
        "user": {
          "type":“text”,
          "boost": 2,
          "doc_values": false,
          …
          …
          …
          }
      }
    }
  }
}
```

```
"type":“text”,
"boost": 2,
"doc_values": false,
"ignore_above": 20,
"fielddata": true,
“index”:false,
"norms": false,
"analyzer": "autocomplete",
"search_analyzer":“standard”,
"similarity":“classic”,
"store": true,
 "fields": {
    "english": {
        "type":     "text",
        "analyzer": "english"
    }
}
,
"properties": {
        "age":  { "type": "integer" },
        "name": {
        "properties": {
            "first": { "type": "text" },
            "last":  { "type": "text" }
          }
        }
    }
```

Object형

매핑 설계시 주의점

1) 동적 매핑은 지양
"index.mapper.dynamic": false

2) _all 기능 disable

3) text 필드 사용 자제 (자연어 검색이 필요한 필드 이외에.)

4) _source 기능 disable (성능 개선 효과가 크진 않고 디스크 사용량에 관련)

5) 검색대상이 되는 필드와 그렇지 않은 필드를 명확히 구별
indexed: false (검색이 필요 없는 필드 대상)

6) 집계 정렬의 대상이 되는 필드와 그렇지 않은 필드를 명확히 구별
doc_values : false (집계 및 정렬이 필요 없는 필드 대상)

7) refresh 타임 조정

실습해보기

매핑을 입력 삭제 수정을 실시해 본다.

실습파일 참조

클러스터 및 색인
운용 기법

병합정책(Merge Policy)

새로 인덱싱된 문서는 우선 Lucene의 IndexWriter에 의해 RAM에 보관

주기적으로 RAM 버퍼가 가득 차거나 Elasticsearch이 flush 또는 refresh를 트리거하면 이 문서들은 디스크의 새 세그먼트에 쓰여짐

세그먼트가 너무 많아지게 되면 병합 정책 및 스케줄러에 따라 병합이 수행

MergeFactor에 의한 세그먼트의 병합 전략

세그먼트를 병합하는 빈도와 크기를 제어

http://blog.mikemccandless.com/2011/02/visualizing-lucenes-segment-merges.html

강제 병합

curl -XPOST 'localhost:9200/news/_forcemerge?pretty'

max_num_segments : 병합될 세그먼트 수

only_expunge_deletes : 삭제 필드가 있는 세그먼트만 실행

flush : 색인후 flush할지 여부 (기본값 true)

리밸런싱(rebalancing)

Elasticsearch에서 적절히 각 노드의 균형을 맞추기 위해 샤드를 재배치 하는 것

리밸런싱 정지

```
"transient" : {
    "cluster.routing.allocation.enable" : "none"
}
```

리밸런싱 재개

```
"transient" : {
    "cluster.routing.allocation.enable" : "all"
}
```

별칭(Alias)

alias를 사용하는 경우

1) 색인을 중단 없이 교체

2) 많은 인덱스의 대표 이름을 붙일때

별칭 입력

```
POST /_aliases
{
    "actions" : [
        { "add" : { "index" : "test1", "alias" : "alias1" } }
    ]
}
```

별칭 제거

```
POST /_aliases
{
    "actions" : [
        { "remove" : { "index" : "test1", "alias" : "alias1" } }
    ]
}
```

조건을 설정 별칭 생성

```
POST /_aliases
{
    "actions" : [
        {
            "add" : {
                "index" : "test1",
                "alias" : "alias2",
                "filter" : { "term" : { "user" : "kimchy" } }
            }
        }
    ]
}
```

```
POST /_aliases
{
    "actions" : [
        {
            "add" : {
                "index" : "test",
                "alias" : "alias1",
                "routing" : "1"
            }
        }
    ]
}
```

템플릿(Template)

색인을 생성시 미리 정의된 색인 구조를 저장해두는 기능 (색인 세팅값, 매핑값)

템플릿 생성

```
PUT _template/template_1
{
 "index_patterns": ["te*", "bar*"],
 "settings": {
  "number_of_shards": 1
 },
 "mappings": {
  "type1": {
   "_source": {
    "enabled": false
   },
   "properties": {
    "host_name": {
     "type": "keyword"
    },
    "created_at": {
     "type": "date",
     "format": "EEE MMM dd HH:mm:ss Z YYYY"
    }
   }
  }
 }
}
```

템플릿 삭제

```
DELETE /_template/template_1
```

템플릿 조회

```
GET /_template/template_1
```

```
PUT /_template/template_1
{
    "index_patterns" : ["*"],
    "order" : 0,
    "settings" : {
        "number_of_shards" : 1
    },
    "mappings" : {
        "type1" : {
            "_source" : { "enabled" : false }
        }
    }
}
```

두 템플릿에 중복 적용될 경우 우선순위 부여

```
PUT /_template/template_2
{
    "index_patterns" : ["te*"],
    "order" : 1,
    "settings" : {
        "number_of_shards" : 1
    },
    "mappings" : {
        "type1" : {
            "_source" : { "enabled" : true }
        }
    }
}
```

재색인(re-index)

하나의 색인에서 다른 색인으로 복사

매핑이 변경될 경우 주로 사용

```
POST _reindex
{
  "source": {
    "index": "news"
  },
  "dest": {
    "index": "new_news"
  }
}
```

```
POST _reindex
{
  "source": {
    "index": "news",
    "type": "article",
    "query": {
      "term": {
        "user":“대한민국"
      }
    }
  },
  "dest": {
    "index": "new_twitter"
  }
}
```

특정 쿼리 조건을 부여 가능

```
POST _reindex
{
  "source": {
    "remote": {
      "host": "http://otherhost:9200",
      "username": "user",
      "password": "pass"
    },
    "index": "source",
    "query": {
      "match": {
        "test": "data"
      }
    }
  },
  "dest": {
    "index": "dest"
  }
}
```

원격서버 리인덱싱

실습해보기

JSON으로 직접 데이터를 입력,수정,삭제 해보기
cerebro 혹은 크롬 Postman 이용

실습파일 참조

감사합니다.

다음회차 내용
Elasticsearch 분석기
1. Elasticsearch에서의 텍스트 데이터 처리 방법 및 분석기 설정
2. 한글 형태소 분석기 설치 및 운영
3. 형태소 분석기 플러그인 개발
- Lucene Analyzer 구조
- 자신만의 customized 형태소 분석기 개발을 위한 Elasticsearch의 플러그인 개발 과정